

Planeamento do projeto:	1
Porque de isolation forest + Classificador?	1
1. Sistema em Dois Estágios (A abordagem mais profissional).....	1
2. Substituir por um Algoritmo Multi-classe.....	1
3. Análise de Importância de Características (Explainability).....	1
Conclusao.....	1

Planeamento do projeto:

Porque de isolation forest + Classificador?

Tinhamos 3 hipoteses:

1. Sistema em Dois Estágios (A abordagem mais profissional)

Em vez de usares apenas um algoritmo, usas uma cascata:

- **Estágio 1 (Isolation Forest):** Atua como um filtro rápido. Ele analisa todo o tráfego e separa o que é "Normal" de "Anomalia".
- **Estágio 2 (Classificador Supervisionado):** Só é ativado quando o Estágio 1 deteta algo. Usa um algoritmo como **Random Forest** ou **SVM** (treinado com classes específicas como *DDoS*, *Port Scanning*, ou *Falha de Sensor*).
- **Vantagem:** Poupa processamento (o classificador complexo só corre quando há problemas) e consegues classificar o tipo para aplicar a mitigação correta.

2. Substituir por um Algoritmo Multi-classe

um dataset bem rotulado (como o *ToN_IoT* ou o *BoT-IoT*), pode-se saltar o Isolation Forest e usar algoritmos que classificam logo o tipo de ataque:

- **Random Forest:** Muito robusto e dá-te a probabilidade de pertencer a cada classe de anomalia.
- **XGBoost / LightGBM:** Extremamente rápidos e precisos para dados de sensores/rede.

3. Análise de Importância de Características (Explainability)

Se quiseses manter o Isolation Forest (por ser leve para IoT), podes usar técnicas de **SHAP** ou **LIME** para perceber *quais* variáveis causaram a anomalia.

- *Exemplo:* Se a anomalia foi causada por um pico súbito de pacotes (Network Traffic), a mitigação é bloquear o IP. Se foi causada por uma temperatura impossível (Sensor Data), a mitigação é marcar o sensor para manutenção.

Conclusão

A escolha final ficou entre a opção 1 e 2.

A decisão veio da resposta de uma única questão: Tenho algum dataset que me ajude a treinar o algoritmo na opção 2? A resposta foi clara pois já há muitos datasets disponíveis na internet (ToN-IoT, BoT-IoT, NSL-KDD) para facilitar a vida nestes casos de desenvolvimento.

- **LightGBM foi o escolhido por ser leve e muito usado no mundo do IoT.** A escolha é válida porque, num cenário real de segurança, saber **o tipo de ataque** (ex: DDoS vs SQL Injection) é o fator crítico para decidir a resposta automática (mitigação). O Isolation Forest sozinho não dá isso.

Site de onde foi retirado dataset para treinar o modelo:

http://cicresearch.ca/IOTDataset/CIC_IOT_Dataset2023/Dataset/

Dataset específico usado para treino:

http://cicresearch.ca/IOTDataset/CIC_IOT_Dataset2023/Dataset/CSV/MERGED_CSV/Merged01.csv

Separei os dados com um ficheiro, agrupando apenas os tipos de anomalias que queria usar para treinar o meu modelo. Que são eles: Tráfego normal, DDoS, Injection e Scanning.

Este dataset tinha um problema, eu tinha as seguintes quantidades de dados por cada género de treino:

DDoS 677271

Normal 16574

Scanning 10766

Injection 7689

Esta discrepância causa-nos um pequeno problema que é o seguinte. Se treinarmos o modelo assim, ele vai ser "preguiçoso". Ele vai perceber que se responder sempre "DDoS", acerta 95% das vezes.

A solução foi limitar o número de dados de DDoS, e limitando-os apenas a 20.000 unidades.

Em Machine Learning, um desequilíbrio de **3 para 1** (como ficara) é considerado "leve". Os algoritmos modernos como o LightGBM lidam com isto a "brincar". Problemas sérios surgem quando temos 100 para 1 ou 1000 para 1 (como tínhas antes com 600k DDoS vs 7k Injection).

Uso do GNS3 para simular a rede, criação de VLANs como mitigação etc